



Módulo 1

Rol del Ingeniero/a de Datos y Ecosistema

Curso: Data Engineer Básico

60 min

Objetivos de Aprendizaje

- Identificar las responsabilidades principales del Data Engineer dentro de una organización
- Diferenciar el rol del Data Engineer frente a otros roles de datos (Data Scientist, Data Analyst, Data Architect)
- Comprender el flujo de datos moderno desde la ingestión hasta el consumo
- Describir los componentes del ecosistema de datos moderno (almacenamiento, procesamiento, gobernanza)

1. ¿Qué es un Data Engineer?

Responsabilidades, habilidades y contexto del rol

Definición

Un **Data Engineer** es el profesional responsable de diseñar, construir y mantener los *pipelines* de datos que permiten a las organizaciones extraer valor de sus activos de datos.

Focus: La infraestructura de datos — la tubería que transporta datos desde las fuentes hasta los destinos donde se consumen.

Responsabilidades Clave

- **Diseño de arquitecturas de datos:** Definir cómo se almacenan, organizan y conectan los datos
- **Construcción de pipelines de ingestión:** Extraer datos desde múltiples fuentes hacia zonas de almacenamiento
- **Transformación y modelado:** Convertir datos crudos en formatos estructurados y útiles
- **Garantía de calidad:** Implementar controles y validaciones para integridad de datos
- **Gobernanza y documentación:** Registrar linaje, origen y transformación de los datos

Habilidades Técnicas Esenciales

Habilidad	Descripción
SQL	Lenguaje fundamental para extracción y transformación
Python / Pandas	Manipulación y transformación de datos estructurados
Bases de datos	Modelos relacionales, documentales y columnares
Cloud Storage	S3, Azure Blob Storage, Google Cloud Storage
Procesamiento	Hadoop, Spark, EMR, Databricks
Git	Control de código y documentación

Habilidades Blandas



Comunicación

Equipos técnicos y de negocio



Resolución de problemas

Pensamiento analítico



Aprendizaje continuo

El ecosistema evoluciona constantemente

2. Diferencias con Data Scientist y Data Analyst

Comprender las distinciones entre roles de datos

Comparación de Roles

Aspecto	Data Engineer	Data Scientist	Data Analyst
Enfoque	Infraestructura y pipelines	Modelos predictivos y ML	Reporting y análisis descriptivo
Entrada	Datos crudos	Datos procesados	Datos en reporting
Salida	Pipelines funcionales, datos silver/gold	Modelos entrenados, predicciones	Dashboards, informes, insights
Pregunta	¿Cómo llevamos datos?	¿Qué predicción?	¿Qué pasó?
Herramientas	SQL, Python, Spark, Airflow, cloud storage	Python, R, scikit-learn, TensorFlow	SQL, Tableau, Power BI, Excel

Analogía: Fábrica de Automóviles

Data Engineer

Diseña y mantiene las cintas transportadoras, brazos robóticos y sistemas de distribución

Data Analyst

Lee indicadores de producción, genera informes de eficiencia

Data Scientist

Diseña nuevos modelos, optimiza rendimiento, predice fallos

Colaboración entre Roles



El Data Engineer actúa como habilitador: Sin pipelines confiables, ni analistas ni científicos pueden hacer su trabajo.

En TransCore

- **Data Engineer:** Construye pipelines desde SAP PM, plataforma IoT y GMAO hacia el Data Lakehouse
- **Data Analyst:** Genera informes semanales de disponibilidad de activos
- **Data Scientist:** Construye modelos predictivos de mantenimiento basándose en telemetría IoT

3. El Ecosistema de Datos Moderno


Evolución histórica y componentes actuales

Evolución Histórica

Componentes del Ecosistema

Componente	Función	Ejemplos
Ingesta	Extraer datos de fuentes	Airbyte, Fivetran, Kafka, Spark Streaming
Almacenamiento	Persistir datos en zonas	S3, ADLS, GCS, HDFS
Procesamiento	Transformar y enriquecer	Spark, Pandas, dbt, Flink
Orquestación	Coordinar pipelines	Airflow, Dagster, Prefect
Catálogo	Documentar datasets	DataHub, Amundsen, Purview
Gobernanza	Calidad, acceso, privacidad	OpenMetadata, Collibra

Patrón de Zonas (Medallero)



TransCore en el Ecosistema

- **Landing zone:** partes_trabajo.csv (SAP PM), telemetria.csv (IoT), ordenes_mantenimiento.csv (GMAO)
- **Silver zone:** Datos validados y enriquecidos listos para transformación
- **Gold zone:** Datasets de negocio agregados (KPIs de disponibilidad, mantenimiento)
- **Serving layer:** Catálogo interno para equipos de operaciones e ingeniería

4. El Data Engineer en el Equipo

Integración organizacional y artefactos producidos

Equipo de Datos Típico

Equipo de Datos

Data Engineer

Infraestructura
y Pipelines

Data Analyst


Reporting
y Análisis

Data Scientist

ML y
Predicciones

Data Architect / Platform

Arquitectura y estándares




Artefactos del Data Engineer

Artefacto	Descripción
Especificación de fuentes	Documento técnico con detalles de cada fuente (tipo, ubicación, credenciales, frecuencia)
Reglas de calidad	Definición de validaciones y acciones ante fallos
Script de ingesta	Código que implementa extracción hacia landing zone
Linaje de datos	Traza documentada del recorrido de datos
Ficha de dataset	Metadatos del dataset publicado (descripción, esquema, propietario, SLA)

Ciclo de Vida del Dato en TransCore

Ciclo de Vida del Dato en TransCore



Skills vs. Responsibilities

Skills que debe tener

- Programación (Python, SQL)
- Bases de datos y cloud storage
- Git y control de versiones
- Diseño de pipelines

Responsabilidades que asume

- Disponibilidad y fiabilidad de pipelines
- Calidad e integridad de los datos
- Documentación y gobernanza
- Colaboración con equipos de negocio

5. Ejercicio: Mapa RACI

15 minutos • Práctica grupal

Ejercicio 1: Mapa RACI del Dominio Asignado

Objetivo: Crear un mapa RACI que defina las responsabilidades del equipo de datos de TransCore para el dominio asignado.

Dominios asignados:

- **Dominio A — Obra Lineal:** Partes de trabajo y telemetría IoT
- **Dominio B — Activos Ferroviarios:** Inventario y órdenes de mantenimiento

Plantilla RACI

Actividad	DE	DA	DS	Arch	BO
Definición de fuentes	R	C	I	A	I
Diseño de pipeline					
Implementación de ingesta					
Definición de reglas de calidad					
Ejecución de validaciones					
Transformación a silver					
Agregación a gold					
Publicación en catálogo					

Leyenda: R=Responsible, A=Accountable, C=Consulted, I=Informed

Entregable

Tabla RACI completada con justificación de cada rol

- Identificar en rojo las áreas donde el Data Engineer tiene más responsabilidad
- Preparar 2-3 minutos para presentar el mapa al grupo

Resumen

Puntos Clave

- **Data Engineer:** Construye la infraestructura de datos (pipelines) que permite a la organización extraer valor de sus datos
- **Diferenciación:** A diferencia de analistas y científicos, el focus está en mover y transformar datos, no en analizarlos
- **Ecosistema:** El stack moderno incluye ingestión, almacenamiento, procesamiento, orquestación, catálogo y gobernanza
- **Patrón de zonas:** Landing → Silver → Gold → Serving es el estándar para organizar datos por nivel de maduración
- **Integración:** El Data Engineer trabaja con arquitectura, negocio y otros roles de datos para entregar valor
- **Artefactos:** Especificaciones, scripts, linaje y fichas de dataset son los entregables típicos del rol

Referencias

Recursos Adicionales

- [Data Engineering Lifecycle](#) — Blog con artículos sobre buenas prácticas
- [The Rise of the Data Engineer](#) — Artículo de referencia sobre la evolución del rol
- [Data Mesh vs Data Lakehouse](#) — Introducción a arquitecturas modernas (Martin Fowler)



¡Gracias!

Módulo 1: Rol del Ingeniero/a de Datos

Data Engineer Básico • TransCore Case Study