



Módulo 2

Del Data Warehouse a los Espacios de Datos

Curso: Data Engineer Básico

60 min

Objetivos de Aprendizaje

- **Explicar** la evolución desde Data Warehouse hacia arquitecturas Data Lakehouse y Data Mesh
- **Identificar** las características y propósito de cada zona en una arquitectura landing/bronze/silver/gold
- **Comparar** los patrones ETL, ELT y CDC para ingestión incremental
- **Diseñar** una arquitectura conceptual de Data Lakehouse para un dominio específico

1. Evolución Arquitectural

De Data Warehouse a Data Lakehouse

Data Warehouse Tradicional

Origen: Años 90, Bill Inmon y Ralph Kimball

- **Schema-on-write:** Estructura definida antes de cargar
- **Datos estructurados** únicamente
- **Modelos dimensionales** para reporting

✓ Ventajas

- Consistencia y reglas de negocio centralizadas
- Reporting estable y predecible

✗ Limitaciones

- Rigidez para cambios
- Alto coste de almacenamiento
- Dificultad con datos no estructurados

Data Lake

- **Concepto:** Repositorio centralizado para *todos* los datos (estructurados y no)
- **Schema-on-read:** Flexibilidad para explorar sin definir estructura upfront

✓ Ventajas


- Flexibilidad total
- Coste menor por almacenamiento
- Ideal para ML y exploración

✗ Problemas comunes

- Data swamp (datos sin gobernanza)
- Falta de calidad
- Difícil encontrar datos útiles

Data Lakehouse: La Síntesis

Evolución Arquitectural: De DW a Lakehouse



Características Clave del Lakehouse

Formato Abierto

Delta Lake, Apache Iceberg, Hudi

Schema Enforcement

Validación al escribir

Transaccionalidad ACID

Consistencia garantizada

ML Ready

Soporte nativo para analytics y ML

Caso TransCore: Combinar datos estructurados (schedules, passenger counts) con no estructurados (sensor logs, maintenance records) → Lakehouse como solución

2. Data Mesh y Data Spaces

Arquitecturas distribuidas

Data Mesh: Principios (Zhamak Dehghani)

1. Ownership Descentralizada

Cada dominio es dueño de sus datos

2. Datos como Producto

Cada dominio provee datos de calidad

3. Plataforma Autoservicio

Infraestructura común para todos

4. Computación Soberana

Procesamiento local, datos federados

Data Spaces

- **Origen:** Iniciativa europea para interoperabilidad de datos

Componentes:

- Conectores de datos federados
- Soberanía y control por propietario
- Estándares: Gaia-X, IDS

Aplicación:

- Sectores regulados
- Finanzas, salud, movilidad
- Interoperabilidad entre organizaciones

Comparativa de Arquitecturas

Data Mesh vs Data Spaces vs Lakehouse


Aspecto	Lakehouse	Data Mesh	Data Spaces
Escala	Empresa	Empresa/Divisiones	Ecosistema
Ownership	Centralizado	Descentralizado por dominio	Federado (estándares)
Gobernanza	Plataforma	Producto	Estándares
Madurez	Consolidado	Emergente	Naciente
Foco	Unificación datos+ML	Dominios autónomos	Interoperabilidad federada

3. Zonas de Datos

Landing, Bronze, Silver, Gold

Patrón de Zonas (Medallero)

Zonas de Datos: Landing → Bronze → Silver → Gold



Naming Conventions & Propósito			
raw/, landing/, inbound/	bronze/, curated/	silver/, business/	gold/, production/
Recibir	Curar	Enriquecer	Servir

Landing Zone (Raw/Inbound)

Propósito: Zona de recepción para datos crudos ingeridos

- Almacena datos *exactamente como llegan*
- Sin transformaciones, sin limpieza
- Retiene toda la información original
- Facilita reprocesamiento si es necesario

Naming:

raw/, landing/, inbound/

TTL: 30-90 días

Datos crudos retenidos para auditoría

Bronze y Silver Zone

Bronze (Raw Refined)

- Schema aplicado (parquet, delta)
- Limpieza básica (deduplicación)
- Validación inicial de calidad
- Particionado optimizado

Caso de uso: Histórico completo, auditoría

Silver (Business Ready)

- Modelos lógicos aplicados
- Reglas de negocio implementadas
- Dimensiones conformadas
- Calidad de datos verificada

Caso de uso: Reporting, ML training

Gold Zone (Production Ready)

Gold Layer

Datos agregados y optimizados para consumo final

Características:

- Cubos y tablas agregadas
- Métricas de negocio pre-calculadas
- Formato optimizado para queries

Casos de uso:

- Analytics ejecutivo
- Productos de datos
- APIs de consumo

Caso TransCore: Dominio pasajeros: landing recibe ticketing → bronze cura validaciones → silver calcula ocupación → gold provee dashboards ejecutivos

4. Patrones de Procesamiento

ETL, ELT y CDC

ETL: Extract, Transform, Load

Source → Extract → Transform → Load → Destination

✓ Ventajas

- Transformaciones complejas fuera del destino
- Seguridad en transformación de datos
- Schema rígido garantiza calidad

✗ Desventajas

- Schema rígido
- Difícil iterar
- Datos crudos se pierden

ELT: Extract, Load, Transform

Source → Extract → Load (raw) → Transform (in-place)

✓ Ventajas

- Flexibilidad total
- Datos crudos siempre disponibles
- Iteración rápida

⚠ Desventajas

- Requiere plataforma potente
- Gobernanza más compleja

CDC: Change Data Capture

Capturar cambios incrementales desde fuentes

Métodos:

- **Log-based:** MySQL binlog, PostgreSQL WAL
- **Timestamp-based:** Polling con fechas
- **Trigger-based:** Triggers en BD fuente
- **Query-based:** Comparación snapshots


Herramientas:

- Debezium
- AWS DMS
- Fivetran
- Airbyte

Casos de uso: Replicación en tiempo real, audit trails, event streaming

Comparativa de Patrones

Patrones de Procesamiento



5. Mini-reto

Elegir enfoque para reporting operativo

Escenario

Eres Data Engineer en TransCore Railway. El director de operaciones necesita un dashboard de ocupación de trenes en tiempo real (actualización cada 15 minutos).

Datos disponibles:

- **Sistema ticketing:** Oracle DB (on-premise)
- **Sensores ocupación:** API REST (JSON cada 30s)
- **Histórico schedules:** Archivos CSV diarios

Preguntas a Resolver

1. ¿Qué patrón de ingestion para cada fuente?

- Ticketing Oracle → ?
- Sensores API → ?
- Historico CSV → ?

2. ¿Qué zonas necesitas y por qué?


3. ¿Qué tecnología recomiendas?

- A: Airbyte (CDC) → Spark → Delta Lake
- B: Fivetran → dbt → Snowflake
- C: Kafka → Flink → Delta Lake

4. ¿Cuál es el tradeoff principal de tu elección?

Arquitectura TransCore Lakehouse

Arquitectura Data Lakehouse para TransCore



Resumen

Puntos Clave

- **Evolución arquitectural:** DW → Data Lake → Lakehouse responde a necesidades de flexibilidad, escala y casos de uso modernos (ML)
- **Data Mesh y Data Spaces** representan descentralización de datos, cada uno con alcance diferente (empresa vs ecosistema)
- **Zonas landing/bronze/silver/gold** permiten gobernanza progresiva y trazabilidad de datos desde raw hasta consumption
- **Patrones ETL vs ELT vs CDC** tienen tradeoffs diferentes; la selección depende de volumen, latencia y complejidad
- **Arquitectura TransCore** demuestra aplicación práctica: múltiples dominios con zonas compartidas y ownership descentralizado

Check de Aprendizaje

Concepto	Entendido	Requiere Repaso
Data Lakehouse vs Data Mesh	☐	☐
Propósito de cada zona	☐	☐
Cuándo usar ETL vs ELT vs CDC	☐	☐
Diseño básico de arquitectura	☐	☐



¡Gracias!

Módulo 2: Del Data Warehouse a los Espacios de Datos

Data Engineer Básico • TransCore Case Study

```
// Plugins plugins: [RevealNotes, RevealMarkdown, RevealHighlight, RevealZoom], {});
```