



Módulo 3

Modelado de Datos: Del Modelo Lógico al Físico

Curso: Data Engineer Básico

90 min

Objetivos de Aprendizaje

- **Diseñar** un modelo lógico de datos organizado por dominios de negocio
- **Diferenciar** entre el enfoque analítico (hechos/dimensiones) y transaccional
- **Implementar** un modelo físico con esquemas, claves y particionado
- **Evaluar** formatos de almacenamiento (CSV vs Parquet)

1. Modelo Lógico por Dominios


Organización según funcionales del negocio

Dominios Identificados en TransCore

Dominio	Descripción	Entidades Principales
Activos Ferroviarios	Infraestructura física	Vías, señales, estaciones
Obras	Mantenimiento y construcción	Proyectos, presupuestos
Partes de Trabajo	Actividades operativas	Partes diarios, horas
Órdenes Mantenimiento	Planificación	Órdenes, prioridad

Modelo Conceptual de Dominios

Modelo Conceptual de Dominios – TransCore



Principios del Modelado por Dominios

Autosuficiencia

Cada dominio tiene límites claros

Trazabilidad

Facilita trazabilidad entre zonas

Relaciones Explícitas

Obra genera Órdenes de Mantenimiento

Gobernanza

Ownership por dominio

2. Hechos vs Dimensiones

Estructura analítica en el Data Lake

Tablas de Hechos

- Representan **eventos o transacciones** del negocio
- Contienen **métricas cuantificables**: cantidades, duraciones, costes
- Gran volumen de filas

Hecho	Descripción	Métricas
fact_ordenes	Órdenes ejecutadas	count_ordenes, duracion_total
fact_partes	Partes registrados	horas_trabajadas, material_usado
fact_obras	Obras en curso	presupuesto, avance_%

Tablas de Dimensiones

Representan **entidades de negocio** que describen los hechos

Contienen **atributos descriptivos**

Volumen menor pero más complejo (muchos atributos)

Dim	Descripción	Atributos Clave
dim_activos	Activos ferroviarios	tipo, ubicación, estado
dim_tiempo	Calendario	año, mes, semana, día_habil
dim_ubicacion	Geografías	región, zona, tramo
dim_contratista	Empresas	nombre, tipo_contrato


Hechos vs Dimensiones en TransCore

Hechos vs Dimensiones en TransCore

Tabla	Tipo	Métricas / Atributos	Volumen
fact_ordenes	HECHO	count_ordenes, duracion_total coste_material, coste_mano_obra	Alto
fact_partes	HECHO	horas_trabajadas, material_usado count_partes	Alto
dim_activos	DIM	tipo, ubicacion, estado fecha_puesta_servicio	Medio
dim_tiempo	DIM	año, mes, semana dia_habil, trimestre	Fijo
dim_contratista	DIM	nombre, tipo_contrato, clasificación	Bajo

Esquema en Estrella

Esquema en Estrella - Órdenes de Mantenimiento



3. Modelo Físico

Esquemas, Claves y Particionado

Implementación en Databricks

```
-- Schema: dominio_mantenimiento
CREATE SCHEMA IF NOT EXISTS dominio_mantenimiento;

-- Tabla de hechos
CREATE TABLE dominio_mantenimiento.fact_ordenes (
  id_orden STRING,
  id_activo STRING,
  id_tipo_orden INT,
  id_contratista STRING,
  fecha_orden DATE,
  prioridad STRING,
  estado STRING,
  duracion_horas DECIMAL(10,2),
  coste_material DECIMAL(12,2),
  coste_mano_obra DECIMAL(12,2)
)
USING delta
PARTITIONED BY (year, month)
TBLPROPERTIES ('delta.autoOptimize.optimize' = 'true');
```

Tipos de Claves

Tipo	Descripción	Ejemplo
Primary Key	Identificador único	id_orden en fact_ordenes
Foreign Key	Relación entre tablas	id_activo → dim_activos.id_activo
Surrogate Key	Clave generada artificialmente	sk_fecha = YYYYMMDD

Estrategias de Particionado

Criterio	Cuándo Usar	Ejemplo
Por fecha	Datos temporales con consultas por período	PARTITIONED BY (year, month)
Por categoría	Datos con cardinalidad moderada	PARTITIONED BY (estado)
Por activo	Consultas frecuentes por ubicación	PARTITIONED BY (id_region)

Best Practices:

- Evitar particiones con >1000 valores distintos
- Usar autoOptimize para compactar archivos pequeños
- Aplicar Z-ORDER en columnas con frecuentes filtros

4. Formatos de Almacenamiento

CSV vs Parquet

Comparativa CSV vs Parquet

CSV vs Parquet – Comparativa

CSV

Comma-Separated Values

- ✓ Legibilidad: Alta (editor texto)
- ✗ Compresión: Baja
- ✗ Rendimiento: Bajo (parseo completo)
- ✗ Schema: No typed

Ingesta, intercambio

Parquet

Columnar, binario

- ✗ Legibilidad: Baja (binario)
- ✓ Compresión: Alta (hasta 75%)
- ✓ Rendimiento: Alto (columnar)
- ✓ Schema: Auto-discovery

Procesamiento analítico

Tiempo de Query (10GB datos)

Parquet: 2.5 GB

~8 seg (5.6x faster)

~45 seg

Recomendación para TransCore

Landing Zone

CSV

Facilidad con sistemas legacy

Bronze/Silver

Parquet + Delta

Transaccionalidad

Gold Zone

Parquet optimizado

Máximo rendimiento

5. Práctica A

Diagrama de Entidades y Flujos entre Zonas

Caso TransCore: Entidades de Mantenimiento

Activos Ferroviarios

id_activo, tipo, descripcion, ubicacion, estado

Órdenes Mantenimiento

id_orden, descripcion, prioridad, estado, fecha_creacion

Obras

id_obra, nombre, presupuesto, fecha_inicio, estado

Partes de Trabajo

id_parte, id_orden, fecha, horas, materiales_usados

Flujo de Entidades entre Zonas

Pasos de la Práctica

1. **Identificar Entidades (5 min)** — Listar 4 entidades, 3-4 atributos clave, clave primaria
2. **Modelo Conceptual (10 min)** — Diagrama ER con cardinalidades: 1 Activo→N Obras, 1 Obra→N Órdenes, 1 Orden→N Partes
3. **Clasificar (5 min)** — Hechos vs Dimensiones basado en volumen y tipo
4. **Mapear Zonas (10 min)** — Landing→Bronze→Silver→Gold con flujos

Criterios de Verificación

Criterio	Puntuación
Identifica las 4 entidades principales	25%
Dibuja relaciones con cardinalidades correctas	25%
Clasifica correctamente hechos vs dimensiones	25%
Mapea el flujo entre zonas del data lake	25%

Resumen

Puntos Clave

- **Modelo por Dominios:** Organizar según límites funcionales facilita gobernanza y trazabilidad
- **Hechos vs Dimensiones:** Hechos=eventos (alto vol), Dimensiones=entidades descriptivas
- **Modelo Físico:** Particionado y formato impactan rendimiento directamente
- **CSV vs Parquet:** CSV para intercambio, Parquet para procesamiento eficiente

Checkpoint

Pregunta: ¿Qué entidad sería un hecho y cuál una dimensión en TransCore?

Respuesta: fact_ordenes es un hecho (registra eventos) mientras que dim_activos es una dimensión (describe activos).



¡Gracias!

Módulo 3: Modelado de Datos

Data Engineer Básico • TransCore Case Study