



Módulo 4

Buckets y Almacenamiento en la Nube

Curso: Data Engineer Básico

90 min

Objetivos de Aprendizaje

- Comprender la arquitectura de almacenamiento de objetos en la nube y su diferencia con sistemas de archivos tradicionales
- Diseñar una estructura lógica de buckets y carpetas para organizar datos por dominio y zona (bronze/silver/gold)
- Configurar políticas de lifecycle para automatizar la transición y eliminación de datos
- Aplicar versionado de objetos para mantener históricos y proteger contra eliminaciones accidentales

1. Introducción a Amazon S3

Conceptos fundamentales del almacenamiento de objetos

¿Qué es Amazon S3?

Amazon S3 (Simple Storage Service) es un servicio de almacenamiento de objetos ofrecido por AWS que proporciona escalabilidad, disponibilidad y durabilidad.

Característica clave: 99.999999999% de durabilidad (11 nueves)

Almacenamiento de Objetos vs Archivos

Clases de Almacenamiento S3

- **S3 Standard:** Datos frecuentemente accedidos
- **S3 Intelligent-Tiering:** Optimización automática
- **S3 Standard-IA:** Acceso infrecuente
- **S3 Glacier:** Archivo de bajo costo
- **S3 Glacier Deep Archive:** Archivo a largo plazo

Nota: La clase correcta depende de la frecuencia de acceso y requisitos de recuperación.

Casos de Uso en Data Engineering

- **Landing zone:** Datos crudos ingeridos
- **Staging area:** Datos en procesamiento
- **Data lake:** Datos analíticos e históricos
- **Backup:** Archivo de datos financieros

2. Estructura de Buckets y Carpetas

Organización lógica para datos industriales

¿Qué es un Bucket?

Un **bucket** es un contenedor de objetos. La estructura dentro de un bucket es plana (los "directorios" son realmente prefijos en las claves de los objetos).

Nomenclatura: <proyecto>-<entorno>-<region>

Ejemplo: transcorespv2-prod-eu-west-1

Estructura de Zonas (Medallero)

Particionamiento por Fecha

Formato AWS Glue/Athena compatible:

```
año=YYYY/mes=MM/dia=DD/
```

Beneficio: Pruning eficiente en consultas por rango de fechas

Caso de Uso TransCore

```
transcore-infra-prod-eu-west-1/
```

```
|— obra-lineal/  
|   |— topografia/  
|   |— ingenieria/  
|   |— mantenimiento/  
|— activos-ferroviarios/  
|   |— vias/  
|   |— estaciones/  
|   |— senalizacion/  
|   |— catenaria/  
|— sensores-iot/  
|   |— temperatura/  
|   |— vibracion/  
|   |— posicion-gps/
```

3. Versionado de Objetos


Control de versiones y protección de datos

¿Por qué usar Versionado?

- **Protección contra eliminaciones:** Una eliminación solo crea un delete marker
- **Recuperación ante errores:** Restaurar versión anterior si datos se corrompen
- **Auditoría:** Mantiene histórico completo de cambios
- **Cumplimiento:** Conservación de datos durante períodos requeridos

Comportamiento con Versionado Activo

Versionado de Objetos en S3



MFA Delete

Para mayor seguridad en producción:

MFA Delete: Requiere autenticación de dos factores para eliminar permanentemente versiones o cambiar el estado del versionado.

4. Políticas de Lifecycle

Automatización de transiciones y expiración

Tipos de Acciones Lifecycle

Acción	Descripción
Transition	Mover objetos a otra clase de almacenamiento
Expiration	Eliminar objetos automáticamente

Cadena de Transiciones Típica

Configuración Lifecycle (Terraform)

```
resource "aws_s3_bucket_lifecycle_configuration" "transcore_lifecycle" {
  bucket = aws_s3_bucket.transcore_storage.id

  rule {
    id      = "raw-data-lifecycle"
    status  = "Enabled"

    filter {
      prefix = "landing/"
    }

    transition {
      days          = 30
      storage_class = "STANDARD_IA"
    }

    transition {
      days          = 90
      storage_class = "GLACIER"
    }
  }
}
```

Consideraciones Importantes

- Las transiciones tienen coste (mover datos entre clases)
- Glacier requiere tiempo de acceso (3-12 horas para Deep Archive)
- Los delete markers pueden acumularse
- Los prefixes deben estar alineados con la estructura

5. Demo: Organización de Bucket

15 minutos - Práctica guiada

Objetivo de la Demo

Demostrar cómo organizar un bucket S3 con estructura de zonas para TransCore, incluyendo políticas de lifecycle.

Escenario: Configurar almacenamiento para gestión de activos ferroviarios

Pasos de la Demo

1. Crear bucket con versioning habilitado
2. Crear estructura de carpetas lógicas por zona
3. Configurar lifecycle para landing zone
4. Simular ingesta de datos y verificar versionado
5. Verificar lifecycle en consola AWS

Comandos AWS CLI

```
# Crear bucket
```

```
aws s3api create-bucket \  
  --bucket transcorespv2-infra-prod-eu-west-1 \  
  --region eu-west-1
```

```
# Habilitar versioning
```

```
aws s3api put-bucket-versioning \  
  --bucket transcorespv2-infra-prod-eu-west-1 \  
  --versioning-configuration Status=Enabled
```

Configurar Lifecycle

```
aws s3api put-bucket-lifecycle-configuration \  
  --bucket transcorespv2-infra-prod-eu-west-1 \  
  --lifecycle-configuration file://lifecycle-landing.json
```

```
{  
  "Rules": [  
    {  
      "ID": "landing-lifecycle",  
      "Status": "Enabled",  
      "Filter": {"Prefix": "landing/"},  
      "Transitions": [  
        {"Days": 7, "StorageClass": "STANDARD_IA"},  
        {"Days": 30, "StorageClass": "GLACIER"}  
      ],  
      "Expiration": {"Days": 90}  
    }  
  ]  
}
```

Verificación

- ☐ Bucket creado con versioning habilitado
- ☐ Estructura de carpetas lógicas creada
- ☐ Policy de lifecycle visible en consola AWS
- ☐ Versiones múltiples de un objeto visibles
- ☐ Coste estimado mensual mostrado

Errores Comunes

Error	Causa	Solución
AccessDenied	Bucket en otra cuenta	Verificar permisos IAM
InvalidBucketState	Versioning suspendido	Re-habilitar versioning
InvalidArgument	Formato JSON incorrecto	Validar JSON con jq

Resumen

Puntos Clave

- **S3 es almacenamiento de objetos:** Estructura plana con prefijos que simulan carpetas
- **Diseño de zonas:** Implementar landing/raw/curated separa datos por estado
- **Versionado es protección:** Habilitar previene pérdidas por errores humanos
- **Lifecycle automatiza costos:** Transiciones a Glacier y expiración controlada
- **Particionamiento fecha:** Usar `año=YYYY/mes=MM/` mejora rendimiento

Referencias

Recursos Adicionales

- [Amazon S3 Documentation](#)
- [S3 Storage Classes](#)
- [S3 Lifecycle Configuration](#)
- [S3 Versioning](#)
- [Well-Architected Framework - Data Lake](#)
- [S3 Security Best Practices](#)



Gracias!

Módulo 4 Completado

Siguiente: Módulo 5 - Ingesta y Transformación de Datos