

Módulo 6

Ingesta y Calidad del Dato

Curso: Data Engineer Básico

2 horas

Objetivos de Aprendizaje

Objetivos de Aprendizaje

- **Diseñar pipelines de ingesta** que integren datos desde fuentes heterogéneas (ficheros, BBDD, APIs)

Objetivos de Aprendizaje

- **Diseñar pipelines de ingesta** que integren datos desde fuentes heterogéneas (ficheros, BBDD, APIs)
- **Aplicar reglas de validación** para garantizar la integridad y calidad de los datos ingestados

Objetivos de Aprendizaje

- **Diseñar pipelines de ingesta** que integren datos desde fuentes heterogéneas (ficheros, BBDD, APIs)
- **Aplicar reglas de validación** para garantizar la integridad y calidad de los datos ingestedos
- **Ejecutar perfilado de datos** utilizando herramientas de profiling para detectar anomalías y estadísticos descriptivos

Objetivos de Aprendizaje

- **Diseñar pipelines de ingesta** que integren datos desde fuentes heterogéneas (ficheros, BBDD, APIs)
- **Aplicar reglas de validación** para garantizar la integridad y calidad de los datos ingestedos
- **Ejecutar perfilado de datos** utilizando herramientas de profiling para detectar anomalías y estadísticos descriptivos
- **Implementar controles de calidad** que aseguren que los datos cumplen los estándares antes de avanzar al procesamiento

1. Ingesta desde Fuentes Heterogéneas

25 minutos

Tipos de Fuentes de Datos

En un ecosistema de datos moderno, las organizaciones enfrentan datos provenientes de múltiples fuentes:

Ficheros y Bases de Datos

- **Ficheros planos:** CSV, TSV, JSON, XML, Parquet, Avro
- **BBDD relacionales:** PostgreSQL, MySQL, SQL Server, Oracle
- **BBDD NoSQL:** MongoDB, Cassandra, DynamoDB

APIs y Sistemas Externos

- **APIs RESTful:** HTTP GET/POST, OAuth2, rate limiting
- **ERP/CRM:** SAP, Salesforce, Dynamics
- **Streaming:** Kafka, Kinesis, Event Hubs

Patrones de Ingesta

Batch Ingestion

Ejecución programada
(diaria, horaria)

- Volúmenes grandes de datos históricos
- Ejemplo: batch diario a las 02:00 UTC

Micro-batch

Latencia reducida (minutos)

- Ventanas pequeñas de procesamiento
- Datos de cambio frecuente


Streaming

Procesamiento en tiempo real

- Datos IoT/telemetría
- Garantías de entrega

Caso TransCore: Batch SAP PM


El caso TransCore utiliza **Batch Ingestion** para integrar datos desde SAP PM:



Detalle: Fichero `partes_trabajo.csv` extraído diariamente a las 02:00 UTC

Caso TransCore: Streaming Telemetria

Datos IoT particionados por hora utilizando **Streaming Ingestion**:



Detalle: Fichero `telemetria.csv` particionado por hora

Consideraciones de Conectividad

Aspecto	Recomendación
Credenciales	Almacenar en vault/secrets manager, nunca en código
Conexiones	Pool de conexiones con retry logic
Timeouts	Definir timeouts apropiados según tipo de fuente
SSL/TLS	Encriptar datos en tránsito, especialmente APIs externas

Error común: Hardcodear credenciales en scripts. Usar siempre un secrets manager.

2. Validaciones y Reglas de Calidad

20 minutos

Framework de Validación en 3 Capas

Capa 1: Validación de Formato

- Verificar esquema esperado (tipos de datos, nullable)
- Validar codificación de caracteres (UTF-8, ISO-8859-1)
- Comprobar estructura del fichero (delimitadores, headers)

Capa 2: Validación Semántica

- Rangos válidos para campos numéricos
- Valores enumerados permitidos
- Formatos de fecha/hora consistentes

Capa 3: Validación de Negocio

- Reglas específicas del dominio
- Integridad referencial entre datasets

- Restricciones temporales

Validaciones Case Study: Partes de Trabajo

Para el fichero `partes_trabajo.csv` (SAP PM):


Campo	Regla de Validación	Código
<code>id_parte</code>	No nulo, formato <code>PT-{YYYYMMDD}-{SEQ:6}</code>	F01
<code>id_equipo</code>	Referencia válida a <code>dim_equipos.id_equipo</code>	F02
<code>fecha_inicio</code>	No nulo, formato ISO 8601	F03
<code>fecha_fin</code>	$\geq$ <code>fecha_inicio</code> , no nulo si estado=COMPLETADO	F04
<code>horas_trabajo</code>	$> 0, \leq 24$	F05
<code>tipo_mantenimiento</code>	$\in \{\text{PREVENTIVO, CORRECTIVO, PREDICTIVO}\}$	F06
<code>estado</code>	$\in \{\text{ABIERTO, EN_PROCESO, COMPLETADO, CANCELADO}\}$	F07

Validaciones Case Study: Telemetria

Para el fichero `telemetria.csv` (datos IoT):

Campo	Regla de Validación	Código
<code>timestamp</code>	No nulo, formato ISO 8601, no futuro	T01
<code>id_sensor</code>	No nulo, longitud 8-12 caracteres	T02
<code>valor</code>	No nulo, numérico, rango según tipo sensor	T03
<code>unidad</code>	$\in \{^{\circ}\text{C}, \text{PSI}, \text{RPM}, \text{V}, \text{A}, \text{Hz}\}$	T04
<code>id_equipo</code>	Referencia válida a <code>dim_equipos.id_equipo</code>	T05

Gestión de Rechazos y Excepciones



Best Practice: Registrar siempre el motivo del rechazo para facilitar debugging y mejora continua.

3. Perfilado de Datos

15 minutos

¿Qué es el Perfilado de Datos?

El **data profiling** es el proceso de examinar los datos para entender su:

- **Estructura:** Columnas, tipos, formatos
- **Contenido:** Valores, distribuciones
- **Calidad:** Nulos, duplicados, outliers

Beneficio clave: Proporciona visibilidad sobre el estado real de los datos antes de procesarlos.

Métricas de Perfilado: Complejidad

Métrica	Descripción	Umbral Típico
Completitud	% de valores no nulos	> 95%
Unicidad	% de valores únicos	Variable según caso
Longitud promedio	Caracteres promedio	Esperado según schema
Cardinalidad	Número de valores distintos	Densidad de datos

Métricas de Perfilado: Estadísticas

Numéricos

- **Media, Mediana, Moda:** Tendencia central
- **Min, Max, Percentiles:** Rango y distribución
- **Desviación estándar:** Dispersión

Categóricos

- **Frecuencia de valores:** Distribución de categorías
- **Moda:** Valor más frecuente
- **Cardinalidad:** # valores únicos

Herramientas de Perfilado

Herramienta	Tipo	Caso de Uso
Pandas Profiling	Biblioteca Python	Informes HTML interactivos
Great Expectations	Framework	Validaciones programáticas
Apache Spark	Motor distribuido	Grandes volúmenes
dbt	Transformación SQL	Tests de datos en modelos

Informe de Perfilado – TransCore

Estructura del informe generado:

```
{
  "dataset": "partes_trabajo",
  "profile_timestamp": "2026-04-21T08:00:00Z",
  "record_count": 15420,
  "columns": {
    "id_parte": {
      "type": "string",
      "completeness": 0.9987,
      "uniqueness": 1.0,
      "pattern": "^PT-\\d{8}-\\d{6}$"
    },
    "horas_trabajo": {
      "type": "numeric",
```


4. Laboratorio

Ingesta file→landing + Informe de Perfilado

60 minutos

Objetivos del Laboratorio

- Implementar un pipeline de ingesta que mueva datos desde ficheros CSV hasta la zona landing
- Aplicar validaciones de formato y calidad
- Generar un informe de perfilado de los datos ingestedos
- Documentar el proceso completo

Requisitos: Python 3.9+, librerías: pandas, great_expectations, pandas_profiling

Datos de Origen

Fichero 1: partes_trabajo.csv

(SAP PM - batch diario)

id_parte	id_equipo	fecha_inicio	fecha_fin	horas_trabajo	tipo_mantenimiento	estado	tecnico_asignado
PT-20260420-000001	EQUIPO-001	2026-04-20T08:00:00	2026-04-20T12:30:00	4.5	PREVENTIVO	COMPLETADO	JUAN_GARCIA
PT-20260420-000002	EQUIPO-002	2026-04-20T09:00:00		0	PREVENTIVO	ABIERTO	MARIA_LOPEZ

Estructura de Salida

```
data/
├── landing/
│   ├── partes_trabajo/
│   │   └── yyyy-mm-dd/
│   │       └── partes_trabajo.csv
│   └── telemetria/
│       ├── yyyy-mm-dd/
│       │   └── hh/
│       │       └── telemetria.csv
├── rejected/
│   ├── partes_trabajo/
│   │   ├── yyyy-mm-dd/
│   │   │   └── rejections.csv
│   └── telemetria/
│       ├── yyyy-mm-dd/
│       │   └── rejections.csv
└── profiling/
    ├── partes_trabajo_profile.html
    └── telemetria_profile.html
```

FASE 1: Preparación del Entorno

Duración estimada: 5 minutos

1. Abrir terminal en directorio del proyecto
2. Crear estructura de carpetas:

```
mkdir -p data/landing data/rejected data/profiling data/logs
```

Verificación: Verificar que los ficheros `partes_trabajo.csv` y `telemetria.csv` están en `data/`

FASE 2: Script de Ingesta de Partes

Duración estimada: 20 minutos

```
import pandas as pd
from datetime import datetime
import os

# Configuración
SOURCE_FILE = 'data/partes_trabajo.csv'
LANDING_BASE = 'data/landing/partes_trabajo'
DATE_TODAY = datetime.now().strftime('%Y-%m-%d')

def ingest_partes():
    # Leer fichero fuente
    df = pd.read_csv(SOURCE_FILE)

    # Crear directorio landing con fecha
```

FASE 3: Validaciones con Great Expectations

Duración estimada: 15 minutos

```
import pandas as pd
import great_expectations as ge

def validate_partes(df):
    df_ge = ge.from_pandas(df)

    # Expectativas de formato
    df_ge.expect_column_to_exist("id_parte")
    df_ge.expect_column_values_to_match_regex(
        "id_parte", r"^PT-\d{8}-\d{6}$"
    )
    df_ge.expect_column_values_to_not_be_null("id_equipo")
    df_ge.expect_column_values_to_be_in_set(
        "tipo_mantenimiento",
        ["PREVENTIVO", "CORRECTIVO", "PREDICTIVO"]
    )
```

FASE 4: Perfilado con Pandas Profiling

Duración estimada: 15 minutos

```
import pandas as pd
from pandas_profiling import ProfileReport

def profile_partes():
    df = pd.read_csv('data/landing/partes_trabajo/2026-04-21/partes_trabajo.csv')

    profile = ProfileReport(
        df,
        title="Perfilado: Partes de Trabajo TransCore",
        explorative=True,
        minimal=False
    )

    profile.to_file('data/profiling/partes_trabajo_profile.html')
    print("Informe generado: data/profiling/partes_trabajo_profile.html")
```

Analizar: ¿Hay valores nulos? ¿Las distribuciones son las esperadas? ¿Hay outliers?

Verificación del Laboratorio

Verificación	Criterio	Estado
Fichero en landing	<code>partes_trabajo.csv</code> existe en <code>data/landing/partes_trabajo/yyyy-mm-dd/</code>	☐
Fichero particionado	<code>telemetria.csv</code> existe en <code>data/landing/telemetria/yyyy-mm-dd/hh/</code>	☐
Validaciones pasan	Al menos 90% de expectativas exitosas	☐
Informe de perfilado	HTML generado en <code>data/profiling/</code>	☐

Resumen

Puntos Clave

Puntos Clave

- **Fuentes heterogéneas:** Las organizaciones integran datos de múltiples fuentes (ficheros, BBDD, APIs, streaming)

Puntos Clave

- **Fuentes heterogéneas:** Las organizaciones integran datos de múltiples fuentes (ficheros, BBDD, APIs, streaming)
- **Patrones de ingesta:** Batch para volúmenes grandes, micro-batch para latencia moderada, streaming para tiempo real

Puntos Clave

- **Fuentes heterogéneas:** Las organizaciones integran datos de múltiples fuentes (ficheros, BBDD, APIs, streaming)
- **Patrones de ingesta:** Batch para volúmenes grandes, micro-batch para latencia moderada, streaming para tiempo real
- **Framework de validación en 3 capas:** Formato → Semántica → Negocio

Puntos Clave

- **Fuentes heterogéneas:** Las organizaciones integran datos de múltiples fuentes (ficheros, BBDD, APIs, streaming)
- **Patrones de ingesta:** Batch para volúmenes grandes, micro-batch para latencia moderada, streaming para tiempo real
- **Framework de validación en 3 capas:** Formato → Semántica → Negocio
- **Perfilado de datos:** Essential para entender estructura, contenido y calidad antes del procesamiento

Puntos Clave

- **Fuentes heterogéneas:** Las organizaciones integran datos de múltiples fuentes (ficheros, BBDD, APIs, streaming)
- **Patrones de ingesta:** Batch para volúmenes grandes, micro-batch para latencia moderada, streaming para tiempo real
- **Framework de validación en 3 capas:** Formato → Semántica → Negocio
- **Perfilado de datos:** Essential para entender estructura, contenido y calidad antes del procesamiento
- **Gestión de rechazos:** Registrar siempre el motivo para facilitar debugging

Case Study TransCore – Resumen

Datos de SAP PM (Batch)

- Partes de trabajo diarios
- Ingesta a las 02:00 UTC
- Validaciones F01-F07

Datos IoT (Streaming)

- Telemetría sensores
- Particionado por hora
- Validaciones T01-T05

Referencias

Recursos Adicionales

- [Pandas IO Tools](#) - Documentación oficial de lectura/escritura de datos
 - [Great Expectations](#) - Framework de validación de datos
 - [Pandas Profiling](#) - Generación de informes de perfilado
 - [Python Datetime](#) - Manipulación de fechas y tiempos
-

Caso TransCore: Pipeline de ingesta para mantenimiento predictivo de equipos

¡Gracias!

Módulo 6: Ingesta y Calidad del Dato

Data Engineer Básico

Preguntas