



Módulo 10

Seguridad y gobernanza

Curso: Data Engineer Básico

1 hora


Objetivos de Aprendizaje

- Comprender los principios fundamentales de seguridad en arquitecturas de datos (tríada CIA)
- Implementar controles de acceso basados en roles (RBAC) para datasets y pipelines
- Aplicar técnicas de cifrado y enmascaramiento de datos sensibles
- Registrar datasets y políticas de acceso en un catálogo de datos empresarial

1. Fundamentos de seguridad en arquitecturas de datos

La tríada CIA como base de la seguridad

La tríada CIA



¿Por qué importa? Todo sistema de información debe garantizar estos tres pilares para proteger sus datos.

Confidencialidad

Garantizar que la información solo sea accesible para quienes tienen autorización

Errores comunes:

- Permisos excesivamente amplios
- Usuarios compartidos
- Falta de clasificación de datos

Buenas prácticas:

- Principio de mínimo privilegio
- Autenticación multifactor
- Clasificación por sensibilidad

Integridad

Asegurar que los datos no sean modificados de forma no autorizada

Aplicaciones en arquitecturas de datos:

- Validación de calidad de datos en pipelines
- Versionado de datasets (time travel)
- Gobernanza de datos con Data Steward
- Inmutabilidad en arquitecturas Data Lake

Disponibilidad

Garantizar el acceso oportuno a la información cuando se requiere

Estrategias clave:

- Redundancia geográfica en storage
- Recuperación ante desastres (DR)
- Monitorización proactiva
- Acuerdos de SLA de disponibilidad

Marco regulatorio aplicable

Normativa	Ámbito	Datos afectados
RGPD	Unión Europea	Datos personales de ciudadanos europeos
HIPAA	EE.UU.	Información sanitaria
PCI-DSS	Global	Datos de tarjetas de pago
ISO 27001	Global	Sistema de gestión de seguridad
NIST CSF	EE.UU. (industrial)	Infraestructuras críticas (SCADA)

Caso TransCore: Los sistemas SCADA deben cumplir con NIST CSF e IEC 62443.

2. Controles AAA: Autenticación, Autorización, Auditoría

El modelo fundamental de control de acceso

Modelo AAA

Controles AAA en Arquitecturas de Datos



Autenticación (Authentication)

Proceso de verificar la identidad de un usuario o sistema

Métodos comunes:

- Credenciales (usuario/contraseña)
- Autenticación multifactor (MFA)
- Certificados digitales
- Federated identity (SAML, OAuth, OIDC)

Azure Data Factory: Managed Identity, Service Principal

Databricks: UC native auth, SSO

Autorización (Authorization)

Determinar qué recursos puede acceder un usuario autenticado

Modelo	Descripción	Uso típico
RBAC	Acceso según rol	Equipos de datos (más común)
ABAC	Acceso según atributos	Políticas complejas
PBAC	Acceso según políticas	Cumplimiento regulatorio

Auditoría (Auditing)

Registro y monitorización de acceso a recursos

Elementos clave de una auditoría efectiva:

- **Log de accesos:** Timestamp, usuario, recurso
- **Resultado:** Éxito o fallo del acceso
- **Retention:** Conservación según regulación (ej: 365 días para RGPD)
- **Inmutabilidad:** Logs no modificables

3. Cifrado y enmascaramiento de datos

Protegiendo datos en tránsito y en reposo

Cifrado en tránsito (Encryption in Transit)

Protección de datos mientras se transmiten entre sistemas

[Aplicación] --TLS 1.3--> [Broker] --TLS--> [Consumer]

Protocolo	Uso
TLS 1.2 / 1.3	Comunicaciones HTTPS, Kafka, DB connectors
SSH	Transferencia de archivos (SCP, SFTP)
mTLS	Comunicaciones mutuamente autenticadas

Cifrado en reposo (Encryption at Rest)

Protección de datos almacenados

Métodos de cifrado:

Nivel	Método	Ejemplo
Almacenamiento	Cifrado de disco completo	LUKS, BitLocker, Azure Disk Encryption
Archivo	Cifrado de archivos individuales	OpenSSL, GPG
Columna	Cifrado de campos específicos	AES-256 en bases de datos

Caso TransCore: Cifrado AES-256 para datos SCADA almacenados.

Enmascaramiento de datos (Data Masking)

Técnica para ocultar información sensible manteniendo la estructura y utilidad

Técnica	Descripción	Uso
Enmascaramiento estático	Reemplaza datos reales con ficticios	Desarrollo, testing
Enmascaramiento dinámico	Oculto datos en tiempo real según permisos	Producción, soporte
Tokenización	Sustituye datos por tokens referenciados	Cumplimiento PCI-DSS
Pseudonimización	Reemplaza identificadores manteniendo referenciabilidad	RGPD

Ejemplo: Enmascaramiento en pipeline Databricks

```
from pyspark.ml.feature import StringIndexer

def mask_pii_columns(df, pii_columns):
    """Aplica enmascaramiento a columnas PII"""
    masked_df = df
    for column in pii_columns:
        # Tokenización simple mediante hashing
        masked_df = masked_df.withColumn(
            f"{column}_masked",
            F.hash(column).cast("string")
        )
    return masked_df
```


Nota: En producción usar bibliotecas especializadas como Apache Spark NLP para enmascaramiento avanzado.

4. Modelo RBAC para datos

Control de acceso basado en roles

Conceptos fundamentales de RBAC

Modelo RBAC: Flujo de Control de Acceso



Elementos del modelo

- **Sujeto**: Usuario o grupo de usuarios
- **Rol**: Conjunto de permisos asociados a una función
- **Permiso**: Capacidad de realizar una operación sobre un recurso
- **Recurso**: Dataset, tabla, archivo, pipeline

Flujo:

Sujeto → Rol → Permiso → Recurso

Un sujeto tiene un rol, que otorga permisos sobre recursos

Definición de roles en un equipo de datos

Rol	Responsabilidades	Permisos típicos
Data Engineer	Desarrollo y mantenimiento de pipelines	READ en landing, WRITE en raw
Data Analyst	Análisis exploratorio	READ en curated
Data Scientist	Modelado predictivo	READ en curated, WRITE en models
Data Steward	Gobierno de datos	READ/WRITE en todas, gestión de catálogo
Admin	Administración global	FULL en todas

Implementación: Azure Data Lake Storage Gen2

```
{
  "roles": {
    "data-engineer": {
      "roleDefinitionId": "Storage Blob Data Contributor",
      "permissions": ["read", "write", "delete"],
      "scope": "https://storage.azure.com/.../curated/"
    },
    "data-analyst": {
      "roleDefinitionId": "Storage Blob Data Reader",
      "permissions": ["read"],
      "scope": "https://storage.azure.com/.../curated/"
    }
  }
}
```

Implementación: Databricks Unity Catalog

```
-- Crear catálogo y esquema
CREATE CATALOG IF NOT EXISTS transcore_catalog;
CREATE SCHEMA IF NOT EXISTS transcore_catalog.raw;
CREATE SCHEMA IF NOT EXISTS transcore_catalog.curated;

-- Asignar permisos por rol
GRANT USE_CATALOG ON CATALOG transcore_catalog TO `data-engineer`;
GRANT USE_SCHEMA ON SCHEMA transcore_catalog.raw TO `data-engineer`;
GRANT READ, WRITE ON SCHEMA transcore_catalog.raw TO `data-engineer`;

GRANT USE_SCHEMA ON SCHEMA transcore_catalog.curated TO `data-analyst`;
GRANT READ ON SCHEMA transcore_catalog.curated TO `data-analyst`;
```

Práctica C: Matriz de permisos y alta en catálogo

30 minutos • Aplicación práctica

Objetivo de la práctica

Objetivo: Diseñar e implementar una matriz de control de acceso RBAC para TransCore y registrar datasets en un catálogo de datos empresarial.

Requisitos previos:

- Acceso a entorno Databricks o Azure Data Lake Storage
- Credenciales con permisos de administración
- Dataset sintético de sensores SCADA

Paso 1: Definir roles y responsabilidades (10 min)

Identificar roles del equipo de datos de TransCore:

Rol	Datos Sensores	Datos Procesados	Reportes	Catálogo
Data Engineer	Read	Write	-	Read
Data Analyst	-	Read	Read	Read
Data Steward	Read	Read	Read	Write
Operador Planta	Read	-	-	-

Paso 2: Implementar RBAC en Unity Catalog (10 min)

```
-- Crear grupos
CREATE GROUP IF NOT EXISTS rg_data_engineers;
CREATE GROUP IF NOT EXISTS rg_data_analysts;
CREATE GROUP IF NOT EXISTS rg_data_stewards;
CREATE GROUP IF NOT EXISTS rg_plant_operators;

-- Permisos para Data Engineers
GRANT USE_CATALOG ON CATALOG transcore_catalog TO `rg_data_engineers`;
GRANT READ, WRITE ON SCHEMA transcore_catalog.raw TO `rg_data_engineers`;
GRANT READ ON SCHEMA transcore_catalog.curated TO `rg_data_engineers`;

-- Permisos para Data Analysts
GRANT USE_CATALOG ON CATALOG transcore_catalog TO `rg_data_analysts`;
GRANT READ ON SCHEMA transcore_catalog.curated TO `rg_data_analysts`;
```

Paso 3: Registrar datasets en el catálogo (10 min)

```
-- Registrar metadatos de clasificación
ALTER TABLE transcore_catalog.raw.sensores_scada
SET TBLPROPERTIES (
    'catalog.description' = 'Datos crudos de sensores SCADA',
    'catalog.classification' = 'CONFIDENTIAL',
    'catalog.owner' = 'data-steward-team',
    'catalog.retention' = '365'
);

ALTER TABLE transcore_catalog.raw.alarmas
SET TBLPROPERTIES (
    'catalog.description' = 'Registro de alarmas del sistema SCADA',
    'catalog.classification' = 'RESTRICTED',
    'catalog.owner' = 'operations-team',
    'catalog.retention' = '730'
);
```

Verificación y errores comunes

Criterios de éxito:

- Matriz de permisos documentada y firmada por Data Steward
- Grupos creados en Unity Catalog
- Permisos asignados según matriz
- Datasets registrados con descripción y clasificación
- Usuario sin permisos recibe AccessDeniedException

Error	Causa	Solución
Permission denied al crear grupo	Falta rol de admin	Solicitar account admin
principal not found	Nombre de grupo incorrecto	Verificar nombre exacto
Alter table failed	Sintaxis incorrecta	Usar TBLPROPERTIES con comillas

Resumen

Puntos Clave

- **Tríada CIA:** Confidencialidad, Integridad y Disponibilidad son los pilares de la seguridad de datos
- **Modelo AAA:** Autenticación (quién es), Autorización (qué puede hacer) y Auditoría (qué hizo)
- **Cifrado:** En tránsito (TLS) y en reposo (AES); elegir según el caso de uso
- **Enmascaramiento:** Tokenización y pseudonimización para proteger PII
- **RBAC:** El modelo más común para control de acceso en equipos de datos
- **Catálogo de datos:** Registro centralizado con metadatos de clasificación y gobernanza

Aplicación al caso TransCore

- Datos SCADA: **Confidencial** (presión, temperatura) o **Restringido** (alarmas)
- Matriz de permisos garantiza acceso solo a personal autorizado
- Enmascaramiento dinámico protege datos durante soporte
- Auditoría permite rastrear acceso a infraestructuras críticas

Próximo paso: Módulo 11 - Capstone INECO con defensa breve

Referencias

Recursos Adicionales

- [Azure Data Lake Storage Gen2 - Access Control](#)
- [Databricks Unity Catalog - Access Control](#)
- [NIST Special Publication 800-53 - Security Controls](#)

Guías internas TransCore:

- Guía de clasificación de datos
- Plantilla de matriz de permisos RBAC



Gracias!
Módulo 10 Completado

Siguiente: Módulo 11 - Capstone INECO