



Módulo 11

Proyecto Capstone – Data Lakehouse TransCore

Curso: Data Engineer Básico

2.5 horas

100% Práctica

Objetivos de Aprendizaje

- **Diseñar** una arquitectura de Data Lakehouse completa integrando zonas landing, bronze, silver y gold
- **Aplicar** reglas de calidad de datos y políticas de lifecycle management en un pipeline end-to-end
- **Documentar** el linaje de datos y los contratos de consumo de datasets críticos
- **Presentar/defender** la solución arquitectónica desarrollada ante el equipo INECO

Case Study: TransCore


Empresa ficticia de logística y transporte

Contexto del Proyecto

TransCore necesita evolucionar su infraestructura de datos hacia un modelo Data Lakehouse moderno.

Objetivo: Simular un escenario real donde aplicar todos los conceptos aprendidos en módulos anteriores.

Arquitectura Objetivo



Leyenda de Zonas:

- Landing: Raw ingestion
- Bronze: Validated raw
- Silver: Cleansed and business ready
- Gold: Aggregations
- Catalogo: Metadata

Fuentes de Datos

Cinco fuentes heterogéneas a ingestar

Especificación de Fuentes

Fuente	Tipo	Formato	Frecuencia
orders.csv	Transaccional	CSV	Diaria
customers.parquet	Dimensión	Parquet	Semanal
shipments_api.json	API REST	JSON	Tiempo real
inventory.db	OLTP	SQLite	Horaria
GPS_events.csv	IoT/Streaming	CSV	Cada 5 min

Modelo Silver/Gold

Estructura de tablas cleansing y agregaciones

Tabla Silver: `silver.orders`

Columna	Tipo	Descripción
<code>order_id</code>	STRING	PK, identificador único
<code>customer_id</code>	STRING	FK a customers
<code>order_date</code>	DATE	Fecha del pedido
<code>total_amount</code>	DECIMAL(10,2)	Importe total
<code>status</code>	STRING	Estado del pedido
<code>ingestion_timestamp</code>	TIMESTAMP	Timestamp de ingesta

Tabla Gold: gold.order_summary

Columna	Tipo	Descripción
order_id	STRING	PK
customer_name	STRING	Nombre del cliente
country	STRING	País del cliente
order_date	DATE	Fecha del pedido
total_amount	DECIMAL(10,2)	Importe total
days_to_delivery	INT	Días desde pedido hasta entrega
kpi_flag	BOOLEAN	Flag para KPIs de negocio

Tabla Gold: gold.inventory_status

Columna	Tipo	Descripción
product_id	STRING	PK
product_name	STRING	Nombre del producto
warehouse_id	STRING	Ubicación
quantity	INT	Stock actual
reorder_point	INT	Punto de reorden
low_stock_alert	BOOLEAN	Alerta de stock bajo

Reglas de Calidad

Validaciones para la zona Silver

Dataset: `orders`

- `order_date` no nulo y válido
- `total_amount` > 0
- `customer_id` existe en customers

Dataset: `customers`

- Email formato válido
- `created_at` no nulo
- `country` en lista válida

Dataset: `shipments`

- `tracking_number` único
- `status` en valores permitidos
- `estimated_delivery` futuro

Dataset: `inventory`

- `quantity` ≥ 0
- `product_id` no nulo
- `warehouse_id` válido

Dataset: `GPS_events`

- `lat/lon` en rango válido
- `timestamp` no nulo
- `vehicle_id` no nulo

Catálogo de Datos Gold

Metadata y contratos de consumo

Dataset: `gold.order_summary`

Owner: Data Team

Sensitivity: Medium

Refresh: Daily

SLA: 06:00 UTC

Dataset: `gold.inventory_status`

Owner: Ops Team

Sensitivity: High

Refresh: Hourly


SLA: 15 min

Lab: Flujo de Desarrollo

Proyecto integrador en 4 fases

Flujo de Desarrollo

Flujo de Desarrollo – Proyecto Capstone



Lab: Requisitos del Proyecto

4 requisitos obligatorios

Requisito 1: Diseño de Arquitectura

Entregable: Documentar

- Diagrama de arquitectura del Data Lakehouse
- Zonas y flujos de datos entre ellas
- Políticas de lifecycle (retención, archivado, eliminación)

Requisito 2: Pipeline End-to-End

Entregable: Al menos un pipeline completo

- Ingesta de fuente a landing
- Transformación landing → bronze → silver
- Agregación silver → gold
- Documentación de linaje

Requisito 3: Calidad de Datos

Entregable: Validaciones implementadas

- Al menos 3 reglas de calidad por dataset
- Logging de excepciones
- Métricas de calidad (% registros válidos, nulls, duplicates)

Requisito 4: Catálogo y Linaje

Entregable: Documentación en plantilla estándar

- Ficha técnica de cada dataset gold
- Linaje desde fuente hasta consumo
- Contratos de consumo (SLA, sensibilidad, owner)

Rúbrica de Evaluación

100 puntos totales

Criterios de Evaluación

Rúbrica de Evaluación – 100 puntos totales

Criterio 1 Arquitectura y Diseño 25 pts Zonas, flujos, políticas lifecycle completas A: 21-25 B: 16-20	Criterio 2 Pipeline End-to-End 25 pts Ingest to Gold completo transforms idempotentes A: 21-25 B: 16-20	Criterio 3 Calidad de Datos 25 pts ≥5 reglas, logging métricas documentadas A: 21-25 B: 16-20	Criterio 4 Catálogo y Linaje 25 pts Fichas completas, linaje trazable, contratos A: 21-25 B: 16-20
--	---	---	--

Escala de Calificación

A 90-100 puntos	B 75-89 puntos	C 60-74 puntos	D 45-59	F 0-44
---------------------------	--------------------------	--------------------------	-------------------	------------------

Desglose por Criterio

Criterio	Excelente	Bueno	Aceptable	Insuficiente
Arquitectura (25pt)	21-25	16-20	11-15	0-10
Pipeline (25pt)	21-25	16-20	11-15	0-10
Calidad (25pt)	21-25	16-20	11-15	0-10
Catálogo (25pt)	21-25	16-20	11-15	0-10

Resumen

Puntos Clave

- **Arquitectura Data Lakehouse:** 4 zonas (Landing, Bronze, Silver, Gold)
- **Pipeline end-to-end:** Ingesta → Transformación → Agregación → Catálogo
- **Calidad de datos:** ≥ 3 reglas por dataset con logging
- **Documentación:** Fichas de catálogo + linaje trazable
- **Defensa:** 5 min presentación + 2 min Q&A por grupo

Referencias

Recursos Adicionales

- [Data Lakehouse Architecture - Databricks](#)
- [Data Quality Framework - dbt](#)
- [Data Catalog Best Practices](#)



Gracias!

Módulo 11 Completado

Curso: Data Engineer Básico

¡Felicitaciones! Has completado el proyecto capstone.